

AWS SAA-C03

Cost Optimization & Well-Architected

Cost Explorer, Budgets, Trusted Advisor, Organizations, Control Tower, DR

Solutions Architect Associate

Dispensa di Studio Approfondita

Strumenti per la gestione dei costi

Ottimizzare i costi e' uno dei cinque pilastri del Well-Architected Framework e un argomento frequente nell'esame SAA-C03. AWS offre diversi strumenti per monitorare, analizzare e ridurre la spesa.

AWS Cost Explorer

Cost Explorer e' lo strumento principale per visualizzare e analizzare i costi AWS. Mostra grafici della spesa nel tempo, suddivisa per servizio, account, regione, tag o altre dimensioni. Puoi creare report personalizzati e salvarli per consultazioni future.

La funzione Forecast usa i dati storici per prevedere la spesa futura. Rightsizing Recommendations analizza l'utilizzo delle istanze EC2 e suggerisce tipi di istanza piu' appropriati (piu' piccoli se sottoutilizzate, piu' grandi se sovraccariche). Savings Plans Recommendations suggerisce quali Savings Plans acquistare in base al tuo utilizzo.

SUGGERIMENTO ESAME: "Analizzare i costi per servizio negli ultimi 6 mesi" = Cost Explorer. "Identificare istanze EC2 sovradimensionate" = Cost Explorer Rightsizing Recommendations.

AWS Budgets

Budgets permette di impostare soglie di spesa e ricevere alert quando vengono superate. Puoi creare budget su costi, utilizzo, copertura di Reserved Instances e Savings Plans.

Gli alert possono essere configurati per notificare quando raggiungi una percentuale del budget (es. 80%) o quando la previsione indica che supererai il budget. Le notifiche vanno a SNS o email.

Budget Actions permettono di eseguire azioni automatiche quando un budget viene superato: applicare una SCP restrittiva, fermare istanze EC2, o disabilitare utenti IAM. Questo e' utile per ambienti di sviluppo o sandbox dove vuoi evitare spese incontrollate.

SUGGERIMENTO ESAME: "Ricevere un alert quando la spesa supera \$1000" = AWS Budgets. "Fermare automaticamente le istanze quando si supera il budget" = Budget Actions.

AWS Cost and Usage Report (CUR)

Il Cost and Usage Report e' il report piu' dettagliato disponibile. Contiene ogni singolo addebito con tutti i dettagli: risorsa, operazione, pricing, tag, ecc. Viene consegnato a un bucket S3 in formato CSV o Parquet.

CUR e' troppo dettagliato per essere letto direttamente. Si usa con strumenti di analytics come Athena (query SQL su S3), QuickSight (visualizzazione), o Redshift (data warehouse) per analisi approfondite.

AWS Trusted Advisor

Trusted Advisor analizza il tuo account e fornisce raccomandazioni su cinque categorie: Cost Optimization (risorse inutilizzate, istanze sottoutilizzate), Performance (limiti di servizio, configurazioni subottimali), Security (permessi troppo aperti, MFA non abilitato), Fault Tolerance (backup mancanti, risorse non distribuite su AZ), e Service Limits (utilizzo vicino ai limiti).

Con il piano di supporto Basic, hai accesso solo a un sottoinsieme di check (principalmente security). Con Business o Enterprise Support, hai accesso a tutti i check e puoi usare l'API per automazione.

SUGGERIMENTO ESAME: "Identificare risorse inutilizzate per ridurre i costi" = Trusted Advisor Cost Optimization. "Verificare che MFA sia abilitato su root" = Trusted Advisor Security.

AWS Compute Optimizer

Compute Optimizer usa machine learning per analizzare l'utilizzo di EC2, Auto Scaling Groups, Lambda e EBS, e raccomandare configurazioni ottimali. A differenza di Cost Explorer Rightsizing che guarda solo EC2, Compute Optimizer copre piu' servizi e fornisce raccomandazioni piu' dettagliate.

Strategie di risparmio

Reserved Instances e Savings Plans

Per workload stabili e prevedibili, Reserved Instances e Savings Plans offrono sconti significativi rispetto a On-Demand.

Le Reserved Instances (RI) sono legate a un tipo di istanza specifico in una regione specifica. Standard RI offrono lo sconto massimo (fino al 72%) ma non possono essere modificate. Convertible RI offrono uno sconto inferiore (fino al 66%) ma permettono di cambiare tipo di istanza, sistema operativo e tenancy durante il periodo.

I Savings Plans sono più flessibili. Compute Savings Plans si applicano a qualsiasi utilizzo EC2, Fargate e Lambda in qualsiasi regione, offrendo fino al 66% di sconto. EC2 Instance Savings Plans sono legati a una famiglia di istanze in una regione specifica ma offrono uno sconto maggiore (fino al 72%).

La scelta tra RI e Savings Plans dipende dalla prevedibilità del tuo workload. Se sai esattamente quali istanze userai per 1-3 anni, le RI Standard offrono il massimo risparmio. Se hai bisogno di flessibilità, i Savings Plans sono preferibili.

SUGGERIMENTO ESAME: "Massimo risparmio per workload EC2 stabile e prevedibile" = Reserved Instances Standard o EC2 Instance Savings Plan. "Risparmio con flessibilità su tipo di istanza e regione" = Compute Savings Plan.

Spot Instances

Le Spot Instances offrono sconti fino al 90% ma possono essere interrotte da AWS con 2 minuti di preavviso quando la capacità è necessaria. Sono ideali per workload fault-tolerant: batch processing, big data analytics, CI/CD, rendering, training di modelli ML.

Le Spot Fleet e gli EC2 Fleet permettono di lanciare un mix di istanze Spot e On-Demand, specificando la capacità desiderata e lasciando che AWS scelga i tipi di istanza più economici disponibili.

SUGGERIMENTO ESAME: "Ridurre i costi per batch processing che può tollerare interruzioni" = Spot Instances.

Altre strategie

S3 Lifecycle Policies spostano automaticamente gli oggetti verso classi di storage più economiche (Standard-IA, Glacier) in base all'età. Questo può ridurre drasticamente i costi di storage per dati acceduti raramente.

Elimina le risorse inutilizzate: volumi EBS non collegati, Elastic IP non associati, snapshot vecchi, load balancer senza target. Trusted Advisor e Cost Explorer aiutano a identificarle.

Usa servizi serverless (Lambda, Fargate, DynamoDB On-Demand) per workload variabili. Paghiamo solo per l'utilizzo effettivo invece di pagare per capacita' provisionata che potrebbe restare inutilizzata.

AWS Organizations e governance multi-account

Struttura e Consolidated Billing

AWS Organizations permette di gestire centralmente più account AWS. Gli account sono organizzati in una gerarchia con Organizational Units (OU). Il Management Account (ex Master Account) è l'account principale che crea e gestisce l'organizzazione.

Consolidated Billing aggrega la fatturazione di tutti gli account in un'unica fattura. Questo non è solo una comodità amministrativa: permette di beneficiare dei volume discounts (più usi, meno paghi per unità) e di condividere Reserved Instances e Savings Plans tra gli account.

Service Control Policies (SCP)

Le SCP definiscono i permessi massimi per gli account o le OU. Non concedono permessi, li limitano. Anche se un utente ha una policy IAM che permette un'azione, se la SCP dell'account non la permette, l'azione è negata.

Casi d'uso comuni: impedire l'uso di regioni non approvate, impedire la disabilitazione di CloudTrail o GuardDuty, impedire la creazione di utenti IAM con accesso programmatico, forzare l'uso di certi tipi di istanze.

Le SCP non si applicano al Management Account. Questo è intenzionale per evitare di bloccarsi fuori, ma significa che il Management Account dovrebbe essere usato solo per la gestione dell'organizzazione, non per workload.

**SUGGERIMENTO ESAME: "Impedire a tutti gli account di usare la regione ap-southeast-1" = SCP.
"Impedire la cancellazione dei log CloudTrail" = SCP.**

AWS Control Tower

Control Tower automatizza il setup e la governance di un ambiente multi-account seguendo le best practice AWS. Crea una Landing Zone con account predefiniti (Log Archive, Audit), OU predefinite, e guardrails (regole di governance).

I Guardrails sono di due tipi: Preventive (implementati come SCP, impediscono azioni non conformi) e Detective (implementati come Config Rules, rilevano configurazioni non conformi).

Account Factory automatizza la creazione di nuovi account con configurazioni standardizzate. Quando un team ha bisogno di un nuovo account, lo richiede tramite Service Catalog e Account Factory lo crea con tutte le configurazioni di governance già applicate.

SUGGERIMENTO ESAME: "Setup automatizzato di un ambiente multi-account con best practice" =

Control Tower. "Creare nuovi account con configurazioni standardizzate" = Account Factory.

Disaster Recovery

Il disaster recovery (DR) e' la capacita' di ripristinare i sistemi dopo un evento catastrofico. AWS offre diverse strategie con trade-off tra costo e tempo di recovery.

RPO e RTO

RPO (Recovery Point Objective) e' la quantita' massima di dati che puoi permetterti di perdere, misurata in tempo. Se il tuo RPO e' 1 ora, devi avere backup almeno ogni ora.

RTO (Recovery Time Objective) e' il tempo massimo che puoi permetterti di restare offline. Se il tuo RTO e' 4 ore, devi essere in grado di ripristinare i sistemi entro 4 ore dal disastro.

Strategie di DR (dal meno al piu' costoso)

Backup and Restore e' la strategia piu' semplice ed economica. Fai backup regolari su S3 (possibilmente in un'altra regione) e, in caso di disastro, ripristini l'infrastruttura dai backup. RPO: ore (dipende dalla frequenza dei backup). RTO: ore (tempo per ripristinare). Costo: basso (solo storage dei backup).

Pilot Light mantiene i componenti core sempre attivi nella regione di DR, tipicamente il database con replica continua. L'infrastruttura di compute (EC2, ASG) e' definita ma non attiva. In caso di disastro, avvii l'infrastruttura e scali alla capacita' necessaria. RPO: minuti (replica del database). RTO: decine di minuti (tempo per avviare e scalare). Costo: medio-basso.

Warm Standby mantiene una versione ridotta dell'ambiente sempre in esecuzione nella regione di DR. Tutti i componenti sono attivi ma con capacita' minima. In caso di disastro, scali alla capacita' piena. RPO: secondi (replica sincrona o quasi). RTO: minuti (solo scaling). Costo: medio.

Multi-Site / Hot Standby mantiene l'ambiente completo attivo in entrambe le regioni, con traffico distribuito tra le due (active-active). In caso di disastro in una regione, tutto il traffico va all'altra. RPO: near zero. RTO: near zero (solo tempo di failover DNS). Costo: alto (paghi per due ambienti completi).

SUGGERIMENTO ESAME: "DR con costo minimo per un'applicazione non critica" = Backup and Restore. "DR con RTO di pochi minuti per un'applicazione critica" = Warm Standby o Multi-Site. "RPO near zero" = replica sincrona (Aurora Global Database, DynamoDB Global Tables).

Servizi AWS per DR

Route 53 Failover routing rileva quando l'endpoint primario non e' healthy e instrada il traffico verso l'endpoint di DR.

Aurora Global Database replica i dati in regioni secondarie con lag inferiore a 1 secondo e permette promozione in meno di 1 minuto. S3 Cross-Region Replication replica gli oggetti in un'altra regione. DynamoDB Global Tables fornisce replica active-active multi-region.

Well-Architected Framework

Il Well-Architected Framework è un insieme di best practice per progettare e operare sistemi affidabili, sicuri, efficienti e cost-effective nel cloud. Si basa su sei pilastri.

Operational Excellence si concentra sull'esecuzione e il monitoraggio dei sistemi per fornire valore di business. Include: operazioni as code (CloudFormation, CDK), cambiamenti piccoli e frequenti, anticipare i fallimenti, imparare dagli incidenti.

Security protegge informazioni, sistemi e asset. Include: identity management forte (IAM, MFA), tracciabilità (CloudTrail, Config), sicurezza a tutti i livelli (VPC, Security Groups, WAF), protezione dei dati (crittografia, backup).

Reliability assicura che un sistema funzioni correttamente e si riprenda dai fallimenti. Include: recovery automatico (Auto Scaling, Multi-AZ), scaling orizzontale, gestione dei cambiamenti (blue/green deployment), test di recovery.

Performance Efficiency usa le risorse di computing in modo efficiente. Include: selezione del tipo di risorsa giusto, monitoraggio delle performance, trade-off informati (es. caching vs freshness).

Cost Optimization evita spese non necessarie. Include: adottare un modello di consumo (pay for what you use), misurare l'efficienza, eliminare sprechi, usare servizi managed.

Sustainability minimizza l'impatto ambientale. Include: comprendere l'impatto, stabilire obiettivi di sostenibilità, massimizzare l'utilizzo, usare servizi managed.

Il Well-Architected Tool nella console AWS ti permette di valutare i tuoi workload rispetto alle best practice dei sei pilastri e ricevere raccomandazioni per migliorare.

SUGGERIMENTO ESAME: Le domande spesso descrivono uno scenario e chiedono quale principio del Well-Architected Framework viene violato o quale soluzione lo rispetta meglio. Familiarizza con i concetti chiave di ogni pilastro.